

EDA & FE

목 차

1. Introduction
2. EDA & Preprocessing
3. FE
4. DA Interview

Introduction

Introduction

“Garbage in, Garbage out”


- 좋은 입력 데이터가 좋은 결과의 기본!
- 아무리 좋은 모델이라도 입력 데이터가 잘 정제되어 있어야 한다.
- 따라서 EDA, 데이터 전처리, Feature Engineering은 모든 프로젝트의 근간이다.
- 각 데이터의 특성을 이해하고, 그 특성들에 맞게 정제해서 모델이 (혹은 사람이) 잘 학습할 수 있는 데이터를 준비하는 작업.



Introduction

- **EDA(Exploratory Data Analysis):** 이게 무슨 데이터고, 어떻게 써먹어야 하나?
 - 주요 작업: 데이터 구조 파악, 변수 타입 및 분포 확인, 이상치 탐색, etc...
 - EDA를 통해서 진행 방향을 결정
- **데이터 전처리:** 실제로 데이터를 쓰기 위해 정제를 해보자~
 - 주요 작업: 결측치 처리, 이상치 제거, 정규화, 범주형 데이터 인코딩, etc...
- **FE(Feature Engineering):** 모델 성능 개선을 위해 데이터를 변형하고 새로운 특성을 만들어보자~
 - 주요 작업: 특성 생성, 특성 제거, 데이터 변형, etc...

데이터 분석 프로세스



EDA & Preprocessing

EDA 과정

1. 데이터 형태 파악

- 데이터의 크기 (행과 열), 변수 이름, 샘플데이터 확인
- 데이터 구조(데이터프레임, 배열 등)을 이해

2. 변수 타입 파악

- 변수들이 숫자형, 범주형, 날짜형인지 확인
- 각 변수의 데이터 타입(int, float, object 등) 검토

3. 결측치, 이상치 확인

- 결측치 비율 파악 및 처리 방안 계획
- 이상치 탐지 및 처리

4. 종속변수의 분포 확인

- 예측 또는 분류 모델에서 목표로 하는 종속변수의 분포 분석
- 분포가 비대칭적일 경우 sampling 등으로 불균형 해소

5. 변수 간 분포 & 변수-종속변수 간 관계 파악

- 각 변수 간 분포 및 상관관계를 탐색하여 데이터 패턴과 특성을 이해

last_name, first_name	player_id	year	pa	k_percent	bb_percent	woba	xwoba	sweet_spot_percent	barrel_batted_rate	hard_hit_percent	avg_best_speed	avg_hyper_speed	whiff_percent	swing_percent
Greene, Riley	682985	2025	397	31.5	6.8	0.374	0.357	39.9	18.1	46.9	102.9310232	95.76236329	32	51.3
Judge, Aaron	592450	2025	429	25.4	16.1	0.484	0.467	37.7	26.3	56.7	106.6911774	98.48560215	35.1	45.8
Carroll, Corbin	682998	2025	361	25.8	8.6	0.37	0.384	32.6	15.2	50.9	104.2249058	96.75233483	26.3	49
Aranda, Jonathan	666018	2025	358	23.7	9.2	0.387	0.399	41.4	12.1	55.7	102.7578239	96.34468576	24.7	48.5
Kepler, Max	596146	2025	313	20.4	11.5	0.301	0.324	31.4	11.4	44.8	100.534185	94.56144359	22.8	47.3
Garcia, Maikel	672580	2025	386	13.5	8	0.352	0.341	34.1	6	44.4	101.4318691	95.00459929	15.6	40.9
Swanson, Dansby	621020	2025	400	26.3	6.8	0.315	0.346	35.1	11.2	47.8	100.9785183	94.94004384	29.9	49
Betts, Mookie	605141	2025	391	10.7	9.2	0.305	0.326	35.4	5.8	35.4	97.80929987	93.12551119	16.7	42.6
Muncy, Max	571970	2025	315	21.9	16.2	0.363	0.392	39.1	14.1	53.1	102.0816373	95.67937229	23.8	43.1
Frelick, Sal	686217	2025	385	12.7	6.8	0.335	0.309	30.7	3	28	96.15641993	92.09430468	11.8	43.7
Gurriel Jr., Lourdes	666971	2025	385	13.8	5.7	0.311	0.313	37.6	6.9	38.9	98.97540333	93.60802246	20.7	52.8
Ortiz, Joey	687401	2025	319	16.3	6.3	0.256	0.281	27.9	3.7	34	98.19510042	93.12088502	16.6	46.2
Domínguez, Jasson	691176	2025	309	28.5	10.7	0.333	0.322	32.1	8	51.3	102.2174015	95.66270813	27.4	50
Contreras, Willson	575929	2025	384	24.5	8.1	0.336	0.371	40	13.9	46.9	103.0445087	95.90172017	27.2	48.7
Flores, Wilmer	527038	2025	347	17.6	8.4	0.31	0.283	34.7	4	24.3	95.3512104	91.69350797	19.1	45.6
Story, Trevor	596115	2025	384	27.9	4.7	0.312	0.313	30.9	10.5	47.3	102.6027422	95.70088083	29.6	54.7
Yelich, Christian	592885	2025	386	26.2	9.6	0.345	0.337	30.5	8.6	46.5	102.3714184	95.39734438	30.3	45.3
Nootbaar, Lars	663457	2025	386	21.5	12.4	0.317	0.33	34	10.4	51.6	102.2020763	95.68829872	20.4	38.3
Caminero, Junior	691406	2025	384	20.3	5.5	0.335	0.333	28.9	10.9	47.2	103.1409187	95.92473092	22.6	50.9
McMahon, Ryan	641857	2025	377	32.1	11.9	0.303	0.33	34.8	11.9	48.1	102.833118	96.23323916	35.1	45.5
Paredes, Isaac	670623	2025	403	16.6	11.9	0.361	0.332	37.4	6	33.1	97.92085843	93.05586749	15.5	40.6
Scott II, Victor	687363	2025	323	27.2	8.4	0.29	0.285	37	4.5	27	96.78880154	92.44017459	29.5	49.1
Arraez, Luis	650333	2025	393	2.8	4.6	0.307	0.287	36.5	0.8	15.7	93.01895222	90.51972046	4.9	50.6
Clement, Ernie	676391	2025	342	10.2	5.8	0.313	0.293	35	1.7	25.5	96.01808128	92.06255424	14.4	53.3
Hoerner, Nico	663538	2025	378	7.4	5.6	0.313	0.305	33.3	2.5	27.5	96.13750385	92.12006938	10.7	49
De La Cruz, Elly	682829	2025	415	24.3	10.1	0.363	0.355	32.2	13	46.7	103.2651746	96.02659295	30	45.3
Bohm, Alec	664761	2025	379	16.4	5.8	0.317	0.325	34.7	6.5	46.7	100.5242466	94.76316464	15.3	48
Arozarena, Randy	668227	2025	412	27.4	10.4	0.358	0.359	35	12.1	52.1	102.5864637	96.06233917	30.4	43.4
Smith, Will	669257	2025	301	18.3	15	0.415	0.402	41.9	13.6	47	101.3009	95.12714909	21.7	38.9
Realmuto, J.T.	592663	2025	324	23.8	7.1	0.311	0.321	37.4	7.7	45	101.290025	94.90754095	24.9	48.5
Becker Jr, Brent	667670	2025	426	31.6	10.1	0.371	0.383	38.8	14.6	48.3	102.0041778	95.61171177	31	48.3

1. 데이터 형태 파악

EDA & Preprocessing

```
df = pd.read_csv('stats.csv')
df.head(5)
```

✓ 0.0s


	last_name, first_name	player_id	year	pa	k_percent	bb_percent	woba	xwoba	sweet_spot_percent	barrel_batted_rate	hard_hit_percent	avg_best_speed	avg_hyper_speed	whiff_percent	swing_percent	is_mvp
0	Greene, Riley	682985	2025	397	31.5	6.8	0.374	0.357	39.9	18.1	46.9	102.931023	95.762363	32.0	51.3	0
1	Judge, Aaron	592450	2025	429	25.4	16.1	0.484	0.467	37.7	26.3	56.7	106.691177	98.485602	35.1	45.8	1
2	Carroll, Corbin	682998	2025	361	25.8	8.6	0.370	0.384	32.6	15.2	50.9	104.224906	96.752335	26.3	49.0	0
3	Aranda, Jonathan	666018	2025	358	23.7	9.2	0.387	0.399	41.4	12.1	55.7	102.757824	96.344686	24.7	48.5	0
4	Kepler, Max	596146	2025	313	20.4	11.5	0.301	0.324	31.4	11.4	44.8	100.534185	94.561444	22.8	47.3	0

Statcast Glossary			
Batting			
Exit Velocity (EV) How fast, in miles per hour, a ball was hit by a batter.	Launch Angle (LA) How high/low, in degrees, a ball was hit by a batter.	Barrels A batted ball with the perfect combination of exit velocity and launch angle	Hard Hit Statcast defines a 'hard-hit ball' as one hit with an exit velocity of 95 mph or higher.
Launch Angle Sweet-Spot A batted-ball event with a launch angle between eight and 32 degrees.	Batted Ball Event (BBE) A Batted Ball Event represents any batted ball that produces a result.	Expected Batting Average (xBA) xBA measures the likelihood that a batted ball will become a hit.	Expected Weighted On-base Average (xwOBA) xwOBA is formulated using exit velocity, launch angle and, on certain types of batted balls, Sprint Speed.
EV50 For a batter, EV50 is an average of the hardest 50% of his batted balls. For a pitcher it is the average of his softest 50% of batted balls allowed.	Adjusted EV Adjusted EV averages the maximum of 88 and the actual exit velocity of each batted ball event.		
Bat Tracking			
Bat Speed Bat speed is measured at the sweet-spot of the bat. Average bat speed is the average of the top 90% of a player's swings.	Fast Swing Rate A fast swing is one that has 75 MPH or more of bat speed.	Swing Length The total (sum) distance in feet traveled of the head of the bat in X/Y/Z space, from start of tracking data until impact point.	Attack Angle The vertical angle at which the sweet spot of the bat is traveling at the point of impact with the ball.
Ideal Attack Angle A ball is hit at an "Ideal Attack Angle," per Statcast, when it is hit with a 5-20° Attack Angle.	Attack Direction The horizontal angle at which the sweet spot of the bat is traveling at the point of impact with the ball, expressed as an angle to the "PULL" or "OPPO" direction.	Swing Path Tilt The vertical angle of the arc traced by the swing path over the 40 ms prior to contact. A higher tilt indicates a "steeper" swing, while a lower tilt indicates a "flatter" swing.	Squared-Up Rate How much exit velocity was obtained compared to the maximum possible exit velocity available, given the speed of the swing and pitch.

1. 데이터 형태 파악

범주형 데이터 인코딩

- Label Encoding
 - 0,1,2,3 할당
 - 장점: 간단하다
 - 단점: 자칫하면 모델이 잘못된 가중치를 줄 수도 있다
 - ex) '등급'과 같이 순서가 있는 범주형 데이터
- One-hot Encoding
 - 각 범주별로 하나의 column 할당 (0,1)
 - 장점: 잘못된 가중치로부터 자유로움
 - 단점: 차원이 급격하게 커짐
 - ex) '색상'처럼 순서 없는 범주형 데이터
- Dummy Encoding
 - One-hot에서 column 하나 제거
 - 장점: 다중공선성 해결
 - 단점: 기준이 되는 범주가 생김(전부 0인 범주)



2. 변수 타입 파악

```
df.dtypes
✓ 0.0s

last_name, first_name  object
player_id              int64
year                  int64
pa                     int64
k_percent              float64
bb_percent             float64
woba                   float64
xwoba                  float64
sweet_spot_percent    float64
barrel_batted_rate     float64
hard_hit_percent      float64
avg_best_speed         float64
avg_hyper_speed        float64
whiff_percent          float64
swing_percent          float64
is_mvp                 int64
dtype: object
```

3. 결측치 확인

```
df.isnull().sum()
✓ 0.0s
```

last_name, first_name	0
player_id	0
year	0
pa	0
k_percent	0
bb_percent	0
woba	0
xwoba	0
sweet_spot_percent	4
barrel_batted_rate	0
hard_hit_percent	0
avg_best_speed	4
avg_hyper_speed	0
whiff_percent	0
swing_percent	0
is_mvp	0
dtype:	int64

```
null_rows = df[df.isnull().any(axis=1)]
print(null_rows)
✓ 0.0s
```

	last_name, first_name	player_id	year	pa	k_percent	bb_percent \
16	Yelich, Christian	592885	2025	386	26.2	9.6
20	Paredes, Isaac	670623	2025	403	16.6	11.9
47	Bogaerts, Xander	593428	2025	379	16.4	10.8
51	Freeman, Freddie	518692	2025	356	22.5	9.3
78	McLain, Matt	680574	2025	357	26.9	9.8
82	Guerrero Jr., Vladimir	665489	2025	414	14.3	13.5
109	Ohtani, Shohei	660271	2025	438	24.9	14.2
113	Torkelson, Spencer	679529	2025	383	24.0	11.5

	woba	xwoba	sweet_spot_percent	barrel_batted_rate	hard_hit_percent \
16	0.345	0.337	30.5	8.6	46.5
20	0.361	0.332	NaN	6.0	33.1
47	0.314	0.337	37.8	5.1	38.9
51	0.361	0.353	NaN	9.2	45.8
78	0.286	0.300	35.3	6.8	41.2
82	0.357	0.402	NaN	13.3	52.9
109	0.410	0.429	31.9	21.7	59.3
113	0.351	0.363	NaN	15.1	44.1

	avg_best_speed	avg_hyper_speed	whiff_percent	swing_percent	is_mvp
16	NaN	95.397344	30.3	45.3	1
20	97.920858	93.055867	15.5	40.6	0
47	NaN	94.256849	19.7	40.4	0
51	100.714303	94.971913	28.2	52.2	0
78	NaN	93.771794	26.4	42.5	0
82	105.637315	97.517251	22.0	41.5	0
109	NaN	98.180938	32.1	44.4	1
113	100.616933	94.677011	26.2	45.1	0

- 결측치 대체 (Imputation)
 - 대표값으로 대체
 - i. 연속형: 중앙값, 평균값
 - ii. 범주형: 최빈값
- 도메인 지식이 필요
(ex: '흡연여부'가 0이면 '흡연 담배 개수'도 0일 것)
- 결측치 자체가 정보를 제공할 수도 있음
(ex: '흡연 담배 개수'가 결측인 데이터에 대해 '비흡연자' 컬럼을 새롭게 만들어 사용할 수 있음)
- 상관관계가 높은 변수들을 사용해서 대체
(ex: '기온'은 '시간'이 비슷한 애들의 구간평균 사용)
- 결측치 비율이 너무 높은 컬럼의 경우 컬럼을 삭제하는 것도 방법임


4. 이상치 확인

[탐지 방법]


1. Standard Deviation (3시그마 규칙)
 - 데이터가 정규분포와 흡사할 때
 - 평균으로부터 표준편차의 3배 이상 떨어진 데이터는 이상치
2. Boxplot으로 IQR 확인
 - $IQR = Q3 - Q1$
 - 하한: $Q1 - 1.5 \times IQR$ / 상한: $Q3 + 1.5 \times IQR$
 - 극단적으로 크거나 작은 값의 영향을 덜 받는다
3. 클러스터링(KNN, DBSCAN)
 - 클러스터링 결과에서 멀리 떨어져있으면 이상치로 간주
4. AutoEncoder
 - 딥러닝으로 알아서 이상치 판별하기

[이상치 처리]

- 제거
- 변환
 - 로그 변환, 제곱근 변환, etc.
- 대체
 - 평균, 최빈값, etc.
- 그대로 활용해도 됨!
 - 사실 이상치가 아닌 경우도 있음
 - 혹은 이상치가 문제해결에 필요할수도 (ex: 이상탐지 모델 개발)




4. 이상치 확인



!!주의!!

이상치 제거는 학습할 때에만 사용

5. 종속변수의 분포 확인



[클래스 불균형]

- 분류 문제의 출력변수 class에 불균형 존재
- 전처리를 잘 거쳐도 성능이 좋지 않은 원인
(ex: False가 많으니 전부 False로 예측해도 모델 성능은 좋아보임)
- 따라서 sampling을 통한 조절 필요

[평가 지표 선정]


- 평가 지표로 정확도 (accuracy)를 사용하면 모델을 잘못 평가할 수 있음
- 정밀도 (Precision): 모델이 '이상치'라고 예측한 것 중, 실제 이상치의 비율
- 재현율 (Recall): 실제 '이상치' 전체 중에서, 모델이 제대로 찾아낸 비율
- F1-Score: 정밀도와 재현율의 조화평균
- PR AUC: X축에는 Recall(재현율)을, Y축에는 Precision(정밀도)을 놓고 임계값 변화에 따라 두 값이 어떻게 변하는지 그린 곡선(PR Curve) 아래의 면적

5. 종속변수의 분포 확인

```
plt.subplot(1,2,1)
df['is_mvp'].value_counts().plot(kind='bar')
plt.title('MVP 분포')
plt.xlabel('MVP 여부')
plt.ylabel('선수 수')
plt.xticks([0,1], ['False', 'True'], rotation=0)
```

✓ 0.1s

([<matplotlib.axis.XTick at 0x20b5d10c140>,
<matplotlib.axis.XTick at 0x20b5ca44290>],
[Text(0, 0, 'False'), Text(1, 0, 'True')])




[Under Sampling]


- 다수 class를 줄이기
- ex: Random, TomekLinks, etc.
- 정보 손실 및 데이터 수 부족으로 인한 과소적합 우려

[Over Sampling]

- 소수 class를 늘리기
- Random, SMOTE, ADASYN, etc.
- 데이터 왜곡 및 과적합 우려



5. 종속변수의 분포 확인




[Focal Loss]

- 소수 class에 대한 loss를 가중치를 더욱 부여


[Minority-aware fine tuning]

- 전체 데이터로 모델 학습 후, 소수 클래스 중심으로 학습하기




6. 변수 분포 & 변수-종속변수 간 관계 파악

- 각 변수 간의 분포 및 상관관계를 탐색하여 데이터의 패턴과 특성 이해
 - 변수와 종속변수 간 관계를 확인하여 중요한 변수(Feature) 식별
 - 다중공선성 해결



[변수들 분포]



[다중공선성]

6. 변수 분포 & 변수-종속변수 간 관계 파악

다중공선성

- 독립변수들 간에 강한 상관관계가 존재하는 현상
- 다중공선성이 존재하는 변수를 함께 사용하면 feature importance가 왜곡될 수 있음


VIF (Variance Inflation Factor)

- 공식: $VIF = 1 / (1 - R^2)$
- 일반적으로 VIF 값이 10 이상이면 다중공선성이 있다고 판단하지만, 절대적인 것은 아님

해결 방법


- 변수 제거: 상관관계 높은 두 변수 중 도메인 중요도 낮은 것 제거
- 변수 결합: 두 변수를 하나의 파생 변수로 합치기 (ex: 평균, 비율)
- 정규화 회귀: Ridge, Lasso 등으로 계수 크기 자체를 제어
- PCA: 상관된 변수들을 주성분으로 축소 (뒤 FE 파트와 연결)

Ridge regression (L2)



Circular region
coefficients shrink
rarely exactly zero

Lasso regression (L1)



Diamond region
has sharp corners
often exactly zero

- - - gray = loss contour (smaller = better fit)

● dot = point where contour touches boundary (solution)

6. 변수 분포 & 변수-종속변수 간 관계 파악

정규화 (Scaling)

- 각 특성들을 일정한 범위로 통일하는 것
- 특성마다 값의 범위가 크게 다르면 모델이 큰 범위의 특성을 지나치게 중요시 할 수도
- KNN, SVM, PCA, ANN 등에서 반드시 해야하는 작업
- 거리, 분산 등에 기반하는 알고리즘에서 매우 중요(Scale에 민감)
- 반면 Decision Tree, 로지스틱 회귀, Bagging/Boosting 등에서는 성능의 변화 없음

```
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
mm_scaler = MinMaxScaler()
sd_scaler = StandardScaler()

# MinMax Scaling
mm_scaler = mm_scaler.fit_transform(train_4['Age'].values.reshape(-1,1))
train['mm_scaled_age'] = mm_scaler

# Standard Scaling
sd_scaler = sd_scaler.fit_transform(train_4['Age'].values.reshape(-1,1))
train['sd_scaled_age'] = sd_scaler
```

6. 변수 분포 & 변수-종속변수 간 관계 파악

정규화 (Scaling)

- 이상치 없으면 Standard, 특정 범위가 필요하면 Min-Max, 이상치 많으면 Robust

1. Standard Scaling (Z-score Normalization)

- 표본평균과 표본 표준편차로 스케일링
- 스케일 없이 단순히 서로간의 거리만 남게 됨
- 평균을 활용하기 때문에 이상치에 취약

$$Z = \frac{X - \bar{X}}{S_X}, \quad \bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n x_i, \quad S_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

2. Min-Max Scaling

- 최대, 최소를 활용해 모든 데이터가 [0, 1] 범위에 존재
- 이상치에 강건

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

3. Robust Scaling


- 중앙값과 IQR값으로 정규화
- 이상치가 많을 때에 유용

$$X' = \frac{X - \tilde{X}}{IQR}$$

Median


Merge, Grouping

- Data Merge – `pd.merge()`



유튜브 : 통계의 도구들

- Data Grouping – `pd.groupby()`



- Data Merge (조인) — `pd.merge()`
 - 두 개 이상의 데이터프레임을 공통된 key(기준 컬럼)를 기준으로 하나로 합치는 작업
 - Inner / Outer / Left / Right 방식에 따라 합쳐지는 범위가 달라짐
- Data Grouping — `pd.groupby()`
 - 특정 컬럼의 값을 기준으로 데이터를 그룹으로 묶고, 그룹별로 집계(평균, 합계, 개수 등)를 계산하는 작업

Feature Engineering

FE(Feature Engineering)

Feature Engineering

Step1.

Feature Selection

choose efficient features
and
abandon useless features

Step2.

Feature Extraction (Dimensional Reduction)

PCA


SVD

LDA

- FE는 Feature Selection + Feature Extraction의 과정
- 얼마나 잘 선택하고 얼마나 잘 합치는가
- PCA: 레이블 없이 분산이 최대인 축을 찾는 비지도 방법
- LDA: 클래스 구분력이 최대인 축을 찾는 지도 방법"

FE(Feature Engineering)

FE



FE는 "특징 생성 → 성능 확인 → 개선"을 반복하는 과정


FE(Feature Engineering)

FE의 목적

- **[Problem] 차원의 저주 (Curse of Dimensionality)**
 - 데이터보다 입력변수가 많아 모델이 복잡할 때 발생
 - 학습 느려지고 과적합 발생
 - 다중공선성 발생으로 인해 모델이 불안정해짐
- **[Solving] 차원 축소 (Dimensionality Reduction) : 모델의 복잡도(차원)을 낮춰 모델 성능을 개선**
- **[How to]**
 - Feature Selection (특징 선택) : 중요한 변수를 선택
 - Feature Extraction (특징 추출) : 기존 변수들을 조합하여 새로운 특성(잠재변수) 생성

Feature Selection – Filter, Wrapper, Embedded

- Filter



- 모델 없이 통계적 지표(상관계수, 카이제곱 검정 등)만으로 변수 선택
- 장점: 빠르고 계산 비용 낮음 / 단점: 변수 간 상호작용 고려 못함


- Wrapper



- 실제 모델을 반복 학습시켜가며 변수 조합 성능 비교
- RFE (Recursive Feature Elimination): 가장 덜 중요한 변수를 하나씩 제거하며 재학습
- 장점: 변수 간 상호작용까지 고려한 최적 조합 / 단점: 계산 비용 매우 높음 (변수 많을수록 느려짐)

Feature Selection – Filter, Wrapper, Embedded

- Embedded



- 모델 학습 과정 자체에 변수 선택이 내장됨
- Lasso: L1 penalty로 계수를 0으로 만들며 자동 선택 (앞 슬라이드 참고)
- 트리 기반 Feature Importance: Random Forest, XGBoost 등에서 분기 기여도로 중요도 산출
- 장점: 학습과 동시에 진행되어 효율적 / 단점: 모델 종류에 따라 결과가 달라질 수 있음

구분	방법	모델 사용	속도	상호작용 고려
Filter	상관계수, 카이제곱	×	빠름	×
Wrapper	RFE	✓ (반복 학습)	느림	✓
Embedded	Lasso, Tree importance	✓ (학습 중 자동)	보통	✓

Feature Extraction – 파생변수 생성

변수의 경향성이 더 뚜렷해지도록 재범주화 하는 과정

[지표 변수] : 지표가 되는 feature를 새로 생성

- ex) ‘나이’를 범주화 하여 ‘young’, ‘middle-aged’, ‘old’로 구분
‘시간’을 범주화 하여 ‘오전’, ‘오후’로 구분

Age	oldness
22.0	young
38.0	middle
26.0	young

[Feature Split] : column 값들을 더 세분화하여 분리

- ex) ‘이름’에서 ‘성’을 분리
‘date’를 ‘year’, ‘month’, ‘day’로 분리

date	year	month	day
2022-02-03	2022	02	03

[시계열 변수] : 시간의 흐름 정보를 반영한 변수 생성

- ex) 특정 시점의 값과 이전 시점의 값을 비교하는 'lag' 변수 생성
최근 N일간의 흐름을 요약하는 '이동평균' 변수 생성
날짜로부터 '요일', '주말 여부' 파생

Data Leakage

- 모델이 실제 예측 시점에는 알 수 없는 정보(주로 test/미래 데이터)가 학습 과정에 새어 들어가, 검증 성능이 실제 성능보다 부풀려지는 현상

Target Encoding Leakage

- 범주형 변수를 "카테고리별 target 평균"으로 인코딩할 때(차원이 클 때)
- 그 행 자신의 target이 평균 계산에 포함되면 → 사실상 정답을 feature로 주는 셈
- 해결: K-fold target encoding (자기 자신이 속한 fold는 제외하고 평균 계산)

시계열 Lag/Rolling Feature Leakage

- "최근 7일 평균 매출" 같은 feature를 만들 때 계산 시점이 예측하려는 시점보다 미래 데이터를 포함하면 안 됨
- 해결: 항상 "현재 시점 이전" 데이터만 사용

이외에도 다양한 형태의 Leakage가 존재함

⚠ Before — leakage

category	target	encoded
A	1	0.50
A	0	0.50
A	1	0.50

그룹 전체 평균을 그대로 사용 → 자기 자신의 target 포함



✓ After — K-Fold

category	target	encoded
A	1	0.00
A	0	1.00
A	1	0.50

자기 자신을 제외한 나머지 행으로만 평균 계산

Feature Extraction – PCA

- PCA (Principal Component Analysis, 주성분 분석)
 - 대규모 데이터 세트의 차원 수를 원본 정보의 대부분을 유지하는 주성분으로 줄인다



- PCA의 직관적 이해
 - 원본 데이터가 타원형을 그림 → 변수 간 상관관계가 존재
 - 상관관계를 반영하여 분산을 가장 잘 설명하는 축(주성분)을 그리고, 직교하는 축들 중 분산을 다음으로 잘 설명하는 축(주성분)을 생성
- 주성분 선정 기준
 - 각 주성분이 전체 분산 중 몇 %를 설명하는지를 그래프로 그려볼 수 있다.
 - 일반적으로 누적 설명력 80~95% 지점에서 주성분 개수를 결정한다.
- 주의사항
 - PC1, PC2는 원래 변수들의 선형결합이라 "이게 무슨 의미인지" 직관적으로 설명하기 어려움
 - Feature Selection과 달리 원본 변수를 그대로 유지하지 않음 → 해석이 중요한 도메인(의료, 금융 등)에서는 신중히 사용


데이터 형식에 따른 전처리

- 텍스트 데이터

- Tokenization: 텍스트를 모델에게 input으로 줄 단위(token)로 분리
(ex: ["텍스트", "데이터", "를", "전", "처리", "합니다"])
- Vectorization: 텍스트를 모델이 이해할 수 있게 벡터화
 - 1) BoW, TF-IDF: 단어의 발생 빈도를 기반으로 벡터화 (문맥 정보 고려X)
 - 2) Embedding: 문맥 정보를 고려하여 단어를 벡터화 (ex: BERT)

- 이미지 데이터

- Data Augmentation – Resize, Crop, Blur, Sharpening, etc.
 - 데이터 부족 문제 해결
 - 모델 일반화 성능 향상



Wrap-up

- EDA의 목적: 데이터를 이해하고, 분석 계획을 수립하기 위한 과정
 - Preprocessing의 목적: 모델 학습이나 분석의 성과를 높이기 위한 정제 작업
 - FE의 목적: 변수들 사이에 숨어있는 정보들을 뽑아내서 모델 학습이나 분석의 성과를 높이기 위한 작업
-
- 적용 순서
 1. EDA (데이터 탐색 및 시각화)
 2. 데이터 정제
 3. Feature Split
 4. Feature Selection/Extraction

DA Interview Question

면접 문제지

다음은 읽고 물음에 답하시오.

(가) 다음 데이터셋은 2025년 한 해 동안 특정 온라인 쇼핑몰을 이용한 고객(10만명) 들의 구매 데이터이다. 고객 별 연간 구매 정보와 개인 상세 정보가 포함되어 있다. (출력값은 전체 데이터셋 중 head(5)를 출력한 결과이다.) 모든 데이터는 2025.12.31. 기준으로 기록된 값이며, 2025년 이전의 데이터는 포함되지 않았다. **이탈 여부**는 마지막 구매 후 180일 이상 구매 이력이 없는 경우 “있음”으로 정의한다. “-”는 기록되지 않은 값이다. (결측치)

고객 ID	연간 구매 금액(만원)	성별	나이	거주지역	회원등급	월평균 방문 횟수	평균 구매 단가(원)	반품횟수	쿠폰 사용률(%)	마지막 구매 후 경과일	추천인 코드 발급 여부	이탈여부
001	85	여	28	서울시 마포구	실버	12	7200	1	45	15	있음	없음
002	420	남	35	경기도 수원시	골드	28	15000	0	-	3	있음	없음
003	12	여	-5	부산시 해운대구	일반	2	-	0	12	180	없음	있음
004	1850	남	44	서울시 강남구	플래티넘	580	92000	8	78	1	있음	없음
005	63	여	71	강원도 춘천시	일반	5	12600	2	0	220	없음	있음




***이 온라인 쇼핑몰은 2025년 6월 이후 무료배송 정책을 시행하였다. (2025년 6월 이전에는 50000원 이상 주문시 무료배송이었음)**

[물음1] 위 데이터를 바탕으로 **고객 이탈을 예측할 수 있는 모델을 구축**하려고 한다. 물음에 답하시오. (단, 종속변수는 위 데이터의 “이탈 여부”를 활용한다)
(1) 제시문 (나)를 참고하여, 고객 이탈 예측 모델 구축 과정에서 수행되는 EDA와 FE(Feature Engineering) 과정에 대해 설명하시오.

면접 문제지 - EDA

[물음1] 위 데이터를 바탕으로 고객 이탈을 예측할 수 있는 모델을 구축하려고 한다. 물음에 답하시오. (단, 종속변수는 위 데이터의 “이탈 여부”를 활용한다)
 (1) 제시문 (나)를 참고하여, 고객 이탈 예측 모델 구축 과정에서 수행되는 EDA와 FE(Feature Engineering) 과정에 대해 설명하시오.

1. 기초 통계량 및 분포 확인
2. 결측치 파악
3. 이상치 탐지
4. 타겟변수(이탈여부) 분포 확인
5. 변수 간 관계 파악
6. 데이터의 맥락(도메인) 특이사항 확인



면접 문제지 - FE

고객 ID	연간 구매 금액(만원)	성별	나이	거주지역	회원등급	월평균 방문 횟수	평균 구매 단가(원)	반품횟수	쿠폰 사용률(%)	마지막 구매 후 경과일	추천인 코드 발급 여부	이탈여부
001	85	여	28	서울시 마포구	실버	12	7200	1	45	15	있음	없음
002	420	남	35	경기도 수원시	골드	28	15000	0	-	3	있음	없음
003	12	여	-5	부산시 해운대구	일반	2	-	0	12	180	없음	있음
004	1850	남	44	서울시 강남구	플래티넘	580	92000	8	78	1	있음	없음
005	63	여	71	강원도 춘천시	일반	5	12600	2	0	220	없음	있음

• 이상치

- 나이가 음숫값 → 데이터 분포의 중앙값/평균값으로 대체하거나 행을 제외함
- 월 방문 횟수 580회는 오류일 가능성이 높으므로 변수에 상한선을 두거나 별도로 처리해야 함

• 결측치

- 결측치가 발생한 이유 파악: 단순 누락, 쿠폰을 사용하지 않음, 구매 이력 부실 등
- 쿠폰 사용률은 0%로, 평균 구매 단가 결측치는 삭제 혹은 연간 구매 금액과 월평균 방문 횟수 등을 고려해 대체할 수 있음
- 결측치가 그 자체로서 의미를 가지는가?

면접 문제지 - FE

마지막 구매 후 경과일	추천인 코드 발급 여부	이탈여부
15	있음	없음
3	있음	없음
180	없음	있음
1	있음	없음
220	없음	있음

추천인 코드 발급 여부	이탈여부
있음	없음
있음	없음
없음	있음
있음	없음
없음	있음

Target Leakage

- 이탈 여부는 마지막 구매 이후 180일 이상 구매 이력이 없는 경우 '있음'으로 정의
- 여기서 '마지막 구매 후 경과일' 컬럼을 제거하지 않으면 **Target Leakage** 발생

범주형 변수 인코딩

- 성별, 추천인코드 발급여부: 이진(0/1) 인코딩
- 회원등급: 일반 - 실버 - 골드 - 플래티넘의 순서 정보가 있으므로 순서형(Ordinal) 인코딩
- 거주지역: One-hot encoding 사용, 차원이 지나치게 커지는 걸 방지하기 위해 시/도 단위로 그룹화 후 인코딩 하는 걸 생각해볼 수 있음

파생변수 생성


- 방문당 평균 구매단가, 쿠폰사용률과 반품횟수를 결합한 "구매 신뢰도" 지표 등

스케일링

- 연간구매금액(단위: 만원)과 평균구매단가(단위: 원)처럼 스케일 차이가 큰 변수들은 표준화(Standardization) 또는 정규화(Min-Max Scaling)를 적용한다.

면접 문제지 - Train-Test Contamination

- 분석가 A: 10만 개의 데이터를 9:1로 random split하고, 9만 개의 데이터를 train set으로 하여 예측 모델 생성
- 분석가 B: **동일한 데이터**를 9.5:0.5로 random split한 후, 9.5만 개의 데이터를 train set으로 하여 예측 모델 생성
- **A의 Test set을 활용하여** A, B 두 모델을 평가했더니 **B의 성능이 월등하게 높게** 나왔다. 이 결과를 신뢰할 수 있는가?



A와 B는 "같은 10만명"을 무작위로 나눈 것이기 때문에,
A의 test set(빨강)에 있던 데이터가 B의 train set(초록)에 들어갈 수 있다.

면접 문제지 - Class Imbalance

- 모델의 정확도(Accuracy)가 88%니, 신뢰할 수 있는 모델이라고 말할 수 있는가?

예측 실제 \	1(이탈)	0(이탈x)
1(이탈)	100	400
0(이탈x)	800	8700

Accuracy = $(100+8700)/10000 = 88\%$ 는 맞지만...
신뢰할 수 있는 모델이라고 이야기할 수는 없음

클래스 불균형(Class Imbalance)

- 실제 이탈 고객은 500명(5%), 비이탈 고객은 9500명(95%)으로 데이터가 심하게 불균형함.
- 이런 상황에서는 모든 고객을 "이탈하지 않음"으로 예측하는 더미 모델조차 정확도 95%를 기록함.
- 따라서 정확도 하나만으로는 이 모델이 실제로 유의미한 예측력을 갖는지 전혀 판단할 수 없다.

→ 클래스 불균형이 존재할 때 Accuracy는 좋은 평가 지표가 아니며,
Recall, Precision, F1-Score 등의 지표를 사용하여 모델을 평가해야 한다.

감사합니다!