

기초 통계

목 차

1. Review
2. Hypothesis Testing
3. Regression Analysis


Review

Brief Review


확률변수 : 표본공간 (발생 가능한 사건의 집합)의 원소를 실수로 대응시키는 함수

기댓값(Expected Value) : 어떤 시행을 무한히 반복했을 때 얻을 수 있는 값들의 평균

분산 (Variable) : 데이터가 평균에서 얼마나 떨어져 있는지를 나타내는 수치




$$E(X) = \begin{cases} \sum_{i=1}^n x_i f(x_i) & (X: \text{이산확률변수}) \\ \int_{-\infty}^{\infty} x f(x) dx & (X: \text{연속확률변수}) \end{cases}$$



모집단과 표본

주제1



표본추출을 통해 모집단을 “추정”한다.

표본분포의 특성에 따라
cluster sampling, stratified sampling,
simple random sampling 등의 방법을
선택한다.


일부를 통해 전체를 평가하는 것이
타당한 접근인가.....?????>?>?>?

공분산과 상관계수

주제1

$\text{Cov}(x,y) = E(xy) - E(x)E(y)$. $\Rightarrow$ 스케일링 : 상관계수 $\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$, $-1 \leq \rho \leq 1$

- 공분산이 0이면 두 확률변수는 서로 독립이다.
- 통계적 상관관계는 인과관계와 다르다 !!!!!!!!!!!




조건부확률과 독립성

주제1

Unknown Known


$$P(A|B) = \frac{P(A \text{ and } B)}{P(B)}$$



$P(A \cap B)$

- Bayes Theorem

$$P(A|B)P(B) = P(B|A)P(A)$$

- 사건 간의 연결고리를 잘 생각해 보자. 어느정도 직관적 사고가 있으면 좋음!
- 내가 모르는 사건을 아는 사건으로 접근하는 데 도움을 준다.

ex. law of total probability

$$E(X) = E(E(X|Y))$$

=> X를 모르니까.. given Y에서 X의 분포를 구하고, 이 조건부 분포의 평균은 Y에 대한 식이니까, 이 식에 대한 평균을 한번 더 내려주는 것 !!!

Hypothesis Testing

Structure

주제2


Step1. 귀무 대립가설 세우기

Step2. 유의수준 선택

Step3. 검정통계량 계산

Step4. p-value 계산

Step5. 귀무가설에 대한 판단
(accept? reject?)



Why??

왜 하필 “귀무가설을 기각“하는 구조일까?

→ 특정 가설이 참임을 데이터로 직접 입증하는 건 논리적으로 불가능에 가깝다.
귀류법을 사용하여 결론의 모순을 찾는 방식으로 접근한다.


귀무가설은 왜 “차이 없음“이 기본값인가? ($H_0 : \mu_1 - \mu_2 = 0$)

→ 목표는 **귀무가설 하**에서 ~~~임을 보이는 것 - 귀무가설은 적어도 계산이 가능해야 한다
: 차이 없음 (딱 하나의 분포)으로 둬으로써 계산을 용이하게 만드는 것

Type 1, 2 error

주제2

Type I error
(false positive)



Type II error
(false negative)



1종오류 : 귀무가설이 실제로 참이지만, 귀무가설을 기각하는 오류

→ 실제 음성인 것을 양성으로 판정

→ 가설검정에서의 α

2종오류 : 귀무가설이 실제로 거짓이지만, 귀무가설을 채택하는 오류

→ 실제 양성인 것을 음성으로 채택하는 오류

→ β (power..)


Tradeoff

이진 분류의 현실 예제


가설(H) 행동(E)			
		 관심없다	 좋아한다
 나의 행동	 고백한다	 최악! [1종오류]	 해피엔딩
	 가만히 있다	 다행!	 아깝! [2종오류]

- H0 : 관심없다! H1 : 그녀도 나를 좋아한다
- H0 기각 : 고백한다 / 채택 : 가만히 있다
- 1종오류 : 관심없는데 고백해서 차임..
(H0 참, H0 기각) → 눈에 보이는 .. 즉각적인 아픔
- 2종오류 : 그녀도 나를 좋아하는데 못 알아채고 놓침
(H0 거짓, H0 채택) → 애초에 놓쳤다는 사실조차 모른다
: 안 보이는 기회비용

- 확신이 서야만 고백한다는 기준을 뻥뻥하게 잡을수록, 차일 위험은 줄어들지만 (1종오류 줄어듦) 진짜 기회를 놓치는 경우 (2종오류) 가 늘어난다
- 조금이라도 신호가 있으면 고백한다고 잡으면.. 차일 위험은 늘어나고 (1종오류 증가) 기회를 덜 놓칠 수 있다 (2종오류 감소)!!



P-value는 “극단성의 척도”



definition: 귀무가설이 참이라 가정했을 때, 지금 관측한 데이터(혹은 그보다 더 극단적인 데이터)가 나올 확률

가정은 이미 고정된 상태에서, 데이터가 그 가정과 얼마나 안 어울리는지를 재는 숫자

P value가 작다

- (1) 진짜 귀무가설이 틀렸다
- (2) 귀무가설이 맞는데.. 우연히 드문 사건이 발생했다

P value가 작다는 것은, 가정과 데이터 사이에 긴장이 크다는 신호일 뿐이다.

증거나 데이터가 불충분하다는 것..

해외 법정에서.. guilty/innocent가 아니라 guilty/ not guilty로 부르는 이유와 같다!

그러나...

Basic format of
Test statistics

=>

$$\frac{\text{관측된 차이}}{\text{그 차이의 불확실성(표준오차)}}$$

표준오차 : 표본크기가 커지면, 작아진다

=> n(표본크기) up => 검정통계량 커짐 => p-value가 자연스럽게 작아질 수 밖에...

가설검정은 만능이 아니다 - 항상 의심하고 또 의심해야 함

즉,, 언제나

p-value, 신뢰구간 모두를 다 살펴보아야 한다!

Common fallacies

1. p값은 모수에 대한 확률이 아니다

p값을 효과가 있다는 대립가설이 틀릴 확률.. 이런 식으로 이해하면 안 된다.
확률은 확률변수에나 쓰는 것.. 여기서의 모수는 unknown constant이다.

2. p값은 귀무가설에 대한 믿음의 “정도”를 주지 않는다

p값이 0.03이다 $\Leftrightarrow$ 귀무가설이 참일 확률이 3%다????????????????????



**중간 다리
하나 빠짐!**

P-value : $P(\text{데이터} | \text{귀무가설})$

귀무가설이 참일 확률이 ~다 : $P(\text{귀무가설} | \text{데이터})$



Confidence Interval

Definition : 이 구간을 만드는 절차를 무한히 반복했을 때, 그렇게 만들어진 구간들 중 ~~%가 true parameter를 포함한다.

- 점추정치는 표본이 바뀔 때 마다 값이 바뀌는 **확률변수** - 추정의 확실성에 대한 정보가 없다.
→ 신뢰구간은 추정의 불확실성을 구간의 폭으로 정량화한다.

- 정확도와 정보량은 서로 **트레이드오프** 관계

정확도 (신뢰수준) 을 올리면 임계값이 커져서 구간이 넓어진다 →
극단적으로, 100% 신뢰구간은 (-무한, 무한) : 아무 정보도 없는 구간..... 정보량 down

- **두 집단** 간의 신뢰구간을 비교하려면.....

$V(x_1 - x_2) = V(x_1) + V(x_2) - 2Cov(x_1, x_2) \rightarrow x_1, x_2$ 의 신뢰구간을 따로 보면,
 $x_1 - x_2$ 의 신뢰구간과 다른 결과가 나올 수도 있다.

Common fallacies

- 이 신뢰구간에 모수가 있을 확률이 95%다 ??????????????????????
 - 95% 신뢰구간이 90% 신뢰구간보다 항상 더 유용하다?????????????????????
신뢰수준을 올리는 것은 더 좋은게 아니라 더 안전하지만 덜 구체적인 것
 - 구간이 좁으면 무조건 다 좋은 추정이다????????????????????????????????
신뢰수준을 고정하지 않고 폭만 비교하면 의미가 없다
- 잘 알고 쓰는 멋진 와빅인이 됩시다..

ANOVA

ANalysis **Of** **VA**riance 분산분석

→ 두개 이상 그룹의 평균 비교를 분산을 통해 분석한다!

Q. 평균 차이를 검정하는데, 왜 분산을 쓰는데?

그룹 평균을 직접 비교하는 것이 아니라, 데이터 전체의 변동을 두 가지로 쪼개서 비교한다

그룹 간 변동 : 각 그룹의 평균들이 전체 평균으로부터 얼마나 떨어져 있는가?

그룹 내 변동 : 같은 그룹 내에서 개별 관측치들이 그룹 평균으로부터 얼마나 떨어져 있는가?

(순수한 잡음)

그래서 왜 분산인가 - 평균 차이 자체는 항상 존재하는데,

“이 차이가 잡음 대비 충분히 큰가?” 를 보는 것이 중요하다

→ 그룹 내 변동 자체가 분산이라서, 분산을 보는 것이 필요함

구조

Step1. 총변동을 분해

$SST = SSB + SSW$ (증명은 어렵지 않아요 ㅎㅎㅎ)

Step2. 자유도로 정규화

각 변동을 자유도로 나누어 평균적인 변동 크기로 만들어 준다.

$MSB : SSB/k-1$, $MSW : SSW/n-k$

Step3. ratio(F statistics) 계산하기

$F : MSB/MSW$

F가 크다 : 그룹 간 신호가 그룹 내 잡음보다 훨씬 크다
→ 우연으로 보기 어렵다 → 유의성 판단해보자!!

Important Assumptions

1. 독립성

관측치끼리 서로 영향을 주면 안 된다.

2. 정규성

F분포는 카이제곱분포의 비율 $\rightarrow$ 카이제곱분포는 표준정규분포의 제곱
 $\rightarrow$ 정규성이 깨지면 f test 자체가 불가능

3. 등분산성

모든 그룹의 모분산이 같아야 한다. 한 그룹이 다른 그룹을 방해해선 안 된다.

검정은 어떻게?

1. 독립성

독립성은 대부분 검정보다는 연구 설계 단계에서 확보하는 가정
(독립성 위반 : 데이터의 수집 방식 / 인접 관측치들의 영향에서 기인함).

시계열처럼 순서가 있는 경우 : Durbin-Watson 검정으로 autocorrelation 확인
일반적인 경우 : 데이터 수집 과정 자체를 점검하자.

2. 정규성


1) Shapiro-wilk test

H_0 : 표본의 모집단이 정규분포를 따른다

Shapiro.test() 메서드를 쓴다

- 표본 크기가 작을 때 많이 쓴다
(표본이 아주 크면 아주 작은 정규성 이탈에도 유의함 → 검정력이 너무 좋아지기 때문)
근데 ? 너무 작아도 검정력이 부족해서 못 잡아냄..

2) Q-Q plot



- 내 데이터의 Quantile(분위수)와 이론적 분포의 분위수를 짝지어서 산점도로 나타낸 것
(이론적 분포의 분위수 → 모집단이 정규분포“였다면”, 이놈의 이론적 분위수는 이 정도였을거다! $F^{-1}(p_i)$ 를 구하는 것
- 산점도가 직선에 가까울수록 정규성 가정이 성립한다.

아근데정규성이없다는데요....어떠카쥬...

Kruskal-Wallis test를 쓰자

- 평균이 아니라 rank 기반으로 비교하는 비모수적 검정법
- 원 자료를 순위로 변환하면, 분포의 모양에 의존하지 않고도 그룹 간 위치를 검정할 수 있겠다! 라는 아이디어에서 시작한 것

항상 분포 가정이 성립한다! 라고 단정짓기는 어렵다

비모수적 검정법도 알라는 두면? 언젠가 쓸 상황이 오지 않을까요

Kruskal-Wallis Test

Test Fundamentals

Kruskal-Wallis test serves a non-parametric alternative to one-way ANOVA for comparing medians across three or more independent groups.

Ranks data instead of using raw values, ou ters

Key assumptions: independent observations

- ordinal or continuous response variables
- similar distribution shapes across groups

Step-by-Step Procedure

- Rank all observations from all groups combined.
- Assign average ranks to ties
- Compute the sum of ranks R_i for each group i , n_i as group size and N as total numb observations

$$H = \frac{12}{N(N+1)} \sum \frac{R_i^2}{n_i} - 3(N+1)$$

$$H = 9.24$$

Step-by-Step Procedure

- Rank all observations from all groups combined.
- Assign average ranks to ties
- Compute the sum of ranks R_i for each group i , n_i as ns group/be as n 2 el N a total observations

$$H = \frac{12}{N(N+1)} \sum \frac{R_i^2}{n_i} - 3(N+1)$$

Practical Applications

- Manufacturing: to compare defect rates across production lines or shifts
- Medical research: ordinal pain scores or skewed biomarker levels across treatment groups
- Social sciences: analyze Likert-scale responses from surveys
- Psychology: compare non-normal behavioral metrics

Example Analysis

Machine A, 5, 7, 6, Machine B 10, 12, 11, and Machine C

Combined ranks: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12
2.5, 5.5, 4, sum $R_A = 12$

Rejects null $p < 0.05$ inoio

한번
읽어보세요!

3. 등분산성

1) Levene's test

- 각 관측치를 그룹 평균으로부터의 절댓값 편차로 변환한 뒤, 그 편차들에 대해 ANOVA를 돌린다

2) Bartlett's test

- Levene's test 보다 검정력은 높다
- 근데.. 정규성 가정에 훨씬 민감하다
- 그래서.. 정규성이 의심스러우면 Levene이 좀 더 안전한 선택

아근데등분산성도없다는데..어떡함??진짜어캄??

주제2

Welch's ANOVA



일반 ANOVA는 SSW 계산 시 모든 그룹이 같은 분산을 공유한다고 가정

웰치스는 그룹별로 분산이 다르다는 걸 인정하고, 자유도 자체를 조정한다!

핵심은.. 같다고 가정 → 어 같지 않네? → 아 그럼 각 그룹 특성 살려서 조정하자

이 아이디어..

One-way anova, Two-way anova

One-way

마케팅 채널에 따라
고객의 평균 금액이 다른가?

마케팅 채널(1개)

TV/SNS/이메일

분석 질문

요인

수준

	이메일	SNS	검색광고
20대	3만원	8만원	5만원
40대	7만원	4만원	5만원

Interaction 체크가
필요한 상황..

Two-way

마케팅 채널 x 고객 연령대에 따라
평균 금액이 다른가?

마케팅 채널, 연령대

각 요인 단독 + Interaction Term

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \epsilon_{ijk}$$

- α_i, β_j : 각 요인의 주효과 — 다른 요인과 무관하게 그 요인 자체가 주는 평균적 영향
- $(\alpha\beta)_{ij}$: 교호작용(**interaction**) — A의 효과가 B의 수준에 따라 달라지는 정도

Why? - H1 : 적어도 하나는 다르다! → 뭐가 다른데?? 어디가 다른데??

F test는 그룹들 간 차이가 있다! 만 알려줄 뿐, 어느 쌍이 다른지는 안알려줌

Tukey HSD (Honestly significant Difference) 다른 방법도 있긴 있는데.. 애를 제일 많이 씀

Key idea : 모든 쌍 중 가장 크게 벌어진 차이를 기준으로 삼아,
전체 오류율을 5%로 통제하면서 모든 쌍을 동시에 비교

판단 기준:

$$|\bar{X}_i - \bar{X}_j| > q_{\alpha, k, N-k} \sqrt{\frac{MSW}{n}}$$

→ 이 값보다 크면 두 그룹은 유의하게 다름

한 줄 포인트: *MSW*는 ANOVA에서 이미 구한 그룹 내 잡음을 그대로 재사용 — 새 정보가 아니라 "같은 잡음 기준자"로 모든 쌍을 한 번에 재는 것

#코드는이런식으로다가..

```
import pandas as pd
from statsmodels.stats.multicomp import pairwise_tukeyhsd
```

```
# data: 'value' 컬럼(반응변수), 'group' 컬럼(그룹 라벨)
tukey = pairwise_tukeyhsd(endog=data['value'],
                           groups=data['group'],
                           alpha=0.05)
```

```
print(tukey)
tukey.plot_simultaneous() # 신뢰구간 시각화
```

8 Turkey HSD 사후검정

File display

In [32]:

```
import pandas as pd
from statsmodels.stats.multicomp import pairwise_tukeyhsd
from statsmodels.formula.api import ols

tukey = pairwise_tukeyhsd(endog=iris['petal_length'], groups=iris['species'], alpha=0.05)
print(tukey)
```

Multiple Comparison of Means – Tukey HSD, FWER=0.05

group1	group2	meandiff	p-adj	lower	upper	reject
setosa	versicolor	2.798	0.0	2.5942	3.0018	True
setosa	virginica	4.09	0.0	3.8862	4.2938	True
versicolor	virginica	1.292	0.0	1.0882	1.4958	True

세 species간 petal_length의 mean은 모든 쌍에서 유의미한 차이를 보인다. setosa-virginica 간 평균차이가 가장 크다.


Regression Analysis

Motivation

상관계수는 두 변수 관계의 방향과 강도만 말해줄 뿐..

X가 1만큼 늘어나면 Y가 얼마나 변하는지? 에 대한 정량적 변화율은 말해주지 않는다.

이 변화율을 추정해주는 것이 회귀분석!! 이다....



How?

주제3

1. 모델 설정

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i$$

여기서 ε_i 는 "우리가 관측하지 못한 모든 것"을 담는 그릇이에요. 회귀는 사실 Y 를 완벽히 설명하려는 게 아니라, 관측된 X 들로 설명 가능한 부분과 그렇지 않은 부분(ε)을 분리하는 작업이라는 걸 강조하면 좋습니다.

2. 최소제곱 목적함수

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (Y_i - X_i^{\top} \beta)^2$$

왜 절대값이 아니라 제곱이냐 — 절대값 손실은 미분 불가능한 점(0)이 있어서 닫힌해를 구하기 어렵고, 제곱손실은 매끄러운 볼록함수라 미분해서 바로 최솟값을 구할 수 있어요.

3. 정규방정식과 행렬 해

행렬 표기로 $Y = X\beta + \varepsilon$ 라 하면, 목적함수를 β 로 미분해서 0으로 놓으면:

$$X^{\top} X \beta = X^{\top} Y$$

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} Y$$

여기서 $(X^{\top} X)^{-1}$ 이 존재해야 한다는 조건이 핵심이에요 — 이게 나중에 다중공선성 문제(→ Ridge)로 이어지는 지점입니다. $X^{\top} X$ 가 특이행렬에 가까워지면(변수 간 거의 완벽한 선형관계) 역행렬이 불안정해져요.

선형회귀

주제3

단순 선형 회귀 Simple Linear Regression

- Sum of Squared Errors 정의

$$SSE = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

- SSE를 각 β_0, β_1 에 대해 미분:

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i)) = 0$$

$$\frac{\partial SSE}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - (\beta_0 + \beta_1 x_i)) = 0$$

- 결과:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

다중 선형 회귀 Multiple Linear Regression

- Sum of Squared Errors 정의

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2 = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)$$

- SSE를 각 β_0, β_1 에 대해 미분:

$$\frac{\partial J}{\partial \beta} = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) \rightarrow \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) = 0$$

- 결과:

$$\mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \mathbf{X} \beta$$

$$\beta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

가정


- 선형성 : y는 x에 대해 선형이다 ($Y=x^2$ 이런 것도 선형.. 파라미터에 대해 선형)
- 등분산성 (잔차) → 위배 시 S.E, p-value, t-stat이 다 틀리게 나옴
- 정규성 (잔차) → 소표본 검정에서 챙겨야 할 것 / 대표본에서는 CLT 덕분에 근사적으로 정규분포가 되어서 ㄱㅏ
- 독립성 (잔차) → 오차들끼리 서로 상관성이 없어야 한다는 것

한 장으로 정리			
가정	없으면 계수($\hat{\beta}$)가	진짜 문제	확인 도구
선형성	왜곡됨	잘못된 관계를 추정	Residual vs Fitted (곡선)
외생성	편향됨	인과 해석 불가능	도메인 지식/설계
등분산성	안 죽음	SE·p-value 틀림, 비효율	Residual vs Fitted (깔때기)
독립성	안 죽음	SE 틀림(대개 과소)	Residual vs Order
정규성	안 죽음	소표본 검정 부정확	QQ Plot


Residual Plot



- 잔차는 “설명되지 못한” 부분 - 랜덤성을 가진다.
- 잔차를 plot으로 그렸을 때, 패턴이 보인다면
→ 잔차에 대한 가정이 많이 흔들리는 것



깔때기 모양 · 등분산성 위배



곡선 패턴 · 선형성 위배

$$Y = \text{결정론적} + \text{확률론적}$$

결정론적 → 우리가 만드는 모델

확률론적 → 모델이 설명하지 못한 부분.. 잔차..!
잔차가 어떤 패턴을 가지면 안 된다.

깔때기 모양

등분산성 위배 → 로그변환, WLS(가중최소제곱) 고려

곡선 패턴

선형성 위배 → 다항항 추가, 비선형모형 고려

결정계수

R^2 : 결정계수 = SSR/SST

$$SST = SSR + SSE$$

$$SST = \sum (Y_i - \bar{Y})^2, \quad SSR = \sum (\hat{Y}_i - \bar{Y})^2, \quad SSE = \sum (Y_i - \hat{Y}_i)^2$$

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

- 종속변수 분산 중 모델이 설명하는 비율


- 주의할 것들

1. 변수를 추가하면 R^2 는 절대 안 줄어든다 → adjusted R^2 사용
2. R^2 가 높다고 예측력 / 인과관계가 보장되지 않는다 : R^2 는 in-sample, 인과관계도 아님
3. R^2 는 관측된 X의 분산 범위에 의존적이다 → 다른 연구나 표본의 R^2 를 단순 비교하는건 위험

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

$$\frac{\beta_1^2 \text{Var}(X)}{\beta_1^2 \text{Var}(X) + \sigma^2}$$

다중공선성



- 설명변수 간 상관관계가 높을 때 발생하는 문제
(설명변수들끼리 서로를 설명해 버리는 상황)
- $X^T X \rightarrow \text{nearly nonsingular} \dots$ 계수 계산이 불가능하거나
계산이 매우 어렵다
- VIF로 진단

$$VIF_j = \frac{1}{1 - R_j^2}$$

VIF>10이면 심각한 다중공선성이다.
(다중공선성 없을 때 분산) * VIF = (있을 때 분산)
- R_j^2 : X_j 를 나머지 설명변수들로 회귀했을 때 결정계수

- 해결방법 : 문제는 변수 간 상관관계가 존재한다는 것 $\rightarrow$ 상관을 제거하자!
- 대표적인 방법이 PCA - 기존의 차원을 직교하는 주성분 차원으로 축소하는 방법
- Ridge $\rightarrow$ 계수 공간을 축소, 분산을 줄인다 : bias up (Bias-variance tradeoff)
- 변수 제거도 방법이긴 한데 omitted variable bias의 우려가 있음

예측력과 해석가능성

- 다중공선성이 있어도 계수는 여전히 unbiased estimator
- 편향이 생기는 것이 아니라, 분산이 폭증하는 것
- 결국, 다중공선성은 전체 모델의 예측력에는 크게 영향을 주지 않을 수도 있다
- 문제는.. 개별 계수 β_j 를 X_j 하나만의 고유한 효과로 해석하려 할 때 발생
→ 표준오차가 커서 통계적으로 유의하지 않거나, 계수 부호가 이론적 기대와 반대일 수 있음

(정리하면)


예측이 목적일 때 다중공선성은 상대적으로 덜 치명적이지만,, 개별 변수의 인과적/구조적 해석이 목적이면 치명적이다.

GLM(Generalized Linear Model)

- 선형회귀의 가정을 만족시킬 수 없는 경우
(Multiple linear regression의 일반화)
- Logistic Regression, Poisson Regression, Ordinal Regression
등등등.....!!

로지스틱 회귀

주제3



- 종속변수가 Binary일 때 (0 또는 1)
우리가 원하는 것은 확률 = $[0,1]$!! → 일반 선형회귀는 0~1 사이의 값만 정확히 뽑아내기 어렵다


- Solution : sigmoid

$$p = P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

- Odds ratio

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X$$

이걸 풀면



$$p = P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

좌변 : 성공 확률 대 실패 확률의 비

계수의 해석 : X가 1만큼 증가할 때, odds가 e^{β_1} 배가 된다

계수의 추정은
gradient descent나 mle로 할 수 있다

감사합니다