

2026 Summer YBIGTA

크롤링

28기 남궁현종

목 차

1. 크롤링이란?
2. 크롤링 도구
3. 실습
4. 과제

크롤링이란?

크롤링이란?

크롤링이란?

sk 하이닉스

전체 쇼핑 뉴스 이미지 동영상 짧은 동영상 더보기 도구

주요 뉴스

매일경제

마켓

매일경제 마켓

SK하이닉스 조달액 256억弗 국내 풀린다 ... 외환시장 숨통 트일까

26분 전

반도체 뉴스

Vietnam.vn

SK하이닉스, AI 열풍에 힘입어 투자 유치 기록 경신.

19분 전

관련 뉴스

경향신문

SK하이닉스 미국 상장 흥행...월요일 코스피, 훈풍 부나

7시간 전

조선일보

SK하이닉스 美 265억달러 유입 진정될까

2시간 전

중양일보

'통화스와프급' 달러 폭탄...SK하이닉스 나스닥 상장, 환율은 웃고 증시는 긴장

34분 전

이데일리

하이닉스 美증시 상장... "AI 메모리 칩 호황 장기화 자신감"

22분 전

네이트

최태원 "맞춤형 칩 키울 것...액면분할도 검토하겠다"

23분 전

모든 언어

모든 날짜

모든 결과

고급검색

모든 언어 ✓

한국어 웹

SK하이닉스

기업

SK하이닉스주식회사는 SK그룹의 계열사로 대한민국의 메모리 반도체 설계·제조 기업이다. DRAM과 낸드플래시를 제조하며 본사는 경기도 이천시 부발읍 경춘대로 2091에 있다.

출처: 위키백과

CEO	곽노창 (2022년 3월 30일-)
본사	이천시
창립자	정주영
창립	1983년 2월

관련 검색어

Micron SAMSUNG SAMSUNG SK Inc.

마이크론 테크 삼성전자 삼성 SK그룹

더보기 >

바야흐로 데이터 홍수 시대!

원하는 정보들을 모두 찾기 위해서
일일이 검색하는 것은 너무 느림...

필요한 정보들을 자동으로
수집하는 방법

크롤링!

크롤링이란?

크롤링이란?

크롤링
= Crawling
= 기어다닌다

어디를? 웹(Web) 상을!
= 웹상을 기어다니며 데이터를 긁어 모은다

왜 필요한가?




데이터를 가지고 분석하고 싶은데... 데이터가 없다!

→ 크롤링을 통해 웹에서 필요한 데이터를 수집한다

크롤링

크롤링이란?

웹상을 기어다닌다?




스크래핑


크롤링이란?

그래서 필요한 정보가 뭔데?

우리가 필요한 정보만 가져오는 것이 바로 스크래핑!



실시간 차트.csv



SK하이닉스,
삼성전자,
SK스퀘어,

...

크롤링과 스크래핑

크롤링이란?

항목	웹 크롤링	웹 스크래핑
목적/용도	특정 키워드에 대한 심층 분석 및 실시간 정보 제공에 유용	정확한 정보를 요구할 때, 장기적 비용 절약 가능
작동 방식	웹 페이지 및 링크를 따라가며 콘텐츠를 자동 수집	웹 포함 다양한 소스에서 필요한 정보만 추출
중복 제어	동일한 콘텐츠가 여러 페이지에 있을 수 있어 중복 제거 필수	특정 정보만 추출하므로 중복 제거는 필수 아님
리소스/확장성	많은 데이터를 수집 가능하지만 서버 부하 큼, 리소스 많이 듦	적은 리소스로 원하는 정보 수집 가능하나 범위 제한 있음
활용 예시	검색포털 - 외부 링크 포함하여 본문 요약 제공	기업 재무정보 자동 수집, 전자상거래 상품 정보 수집 등

실질적으로는 용어를 많이 혼용, 하지만 원리 차이는 알 필요가 있다

HTML(HyperTextMarkupLanguage)

- HyperText (웹 페이지에서 다른 페이지로 이동할 수 있는 것) 기능을 가진 문서를 만드는 언어, 웹 페이지를 위한 마크업 언어

쉽게 말하면 그냥 웹 페이지의 뼈대를 구성하는 언어!

- **마크업 언어**: 마크업 태그로 문서를 표현하는 언어
- **마크업 태그**: 문서의 구조를 표현하는 역할을 하는 표식
- 웹 브라우저는 HTML로 정의된 콘텐츠를 시각적으로 렌더링하는 역할

태그(Tags)

크롤링이란?

:HTML 엘리먼트의 시작과 끝을 지정하기 위한 표현

구성

- 시작 태그 : 각 괄호 안 태그 이름 <태그이름>
- 종료 태그 : 각 괄호 안 슬래시로 시작하는 태그 이름 <태그이름>

시작태그

내용

종료태그

<tagname>환영합니다 29기</tagname>

속성(Attributes)

크롤링이란?

:HTML 문서에서 엘리먼트에 추가적인 정보를 넣을 때 사용되는 요소

표현방식: <태그이름 속성이름="속성값">

속성은 CSS를 사용할 때 활용

속성이름

속성값

<tagname attr="value">환영합니다 29기</tagname>

엘리먼트(Elements)

크롤링이란?

:HTML을 구성하는 객체, 스타트 태그부터 끝마침 태그까지를 모두 포함하는 것
=HTML은 엘리먼트들의 집합임

엘리먼트



```
<tagname attr="value">환영합니다 29기</tagname>
```

HTML 문서의 예

크롤링이란?

```
<!DOCTYPE html>
<html>
  <body>
    <h1>Welcome to ybigta</h1>
    <p>Crawling is useful..</p>
  </body>
</html>
```

- !DOCTYPE는 문서종류의 정의
-html 타입의 문서이다
- <html>과 </html> 사이에 웹페이지
전체 내용이 들어감
- <body>와 </body> 사이에는
그 중 보이는 내용이 들어감
- <h1>와 </h1> 사이에는 제목 작성
- <p>와 </p> 사이에는 문단 작성

REQUESTS

크롤링이란?

GET 요청

- 페이지 열람, 검색 등 읽기 작업
- 크롤링의 핵심

```
import requests

res = requests.get("https://example.com")
print(res.text)
```

POST 요청

- 로그인, 데이터 제출 등 쓰기 작업
- Selenium으로 주로 대응
- 응답코드
200: 정상, 403/404: 차단·오류 체크 중요

크롤링 도구

BeautifulSoup

크롤링 도구

html과 xml 문서를 parsing하기 위한 패키지로
html에서 데이터를 추출하는 데 유용한 분석 트리 생성하는 기능을 제공

파이썬 내장 모듈인 requests나 urllib을 이용해 html을 다운 받고,
beautifulsoup으로 데이터를 추출함

장점 : 간단한 코드, 빠른 속도

단점 : 동적 페이지에서의 크롤링이 까다로움

BeautifulSoup

Selenium

크롤링 도구

웹 브라우저를 이용하여 웹 사이트에서의 자동 제어 기능을 제공

Chrome 브라우저를 사용하며 실제 페이지에서의
키보드와 마우스로 수행하는 동작을 자동화함
웹 사이트에서 동적으로 활용하기 유리

장점 : 버튼 클릭, 스크롤 등의 조작이 가능함

단점 : 복잡한 코드, 느린 속도



robots.txt 확인

- 사이트가 크롤링을 허용하는지 여부를 명시해 놓은 파일
- 대부분의 사이트에서 주소 뒤에 /robots.txt 붙여 확인 가능

사이트 부하 방지

- 요청 간 시간 간격 주기: time.sleep(1~3초) 권장
- 너무 많은 페이지를 짧은 시간에 긁지 않기
- User-Agent 설정도 필요 시 고려

법적 이슈 주의

- 개인정보, 유료 서비스 크롤링 금지
- 학습, 비영리 목적으로 제한적 사용 권장

자기자신을 위한 주의사항! CAPTCHA 같은 보안 기능이 있는 사이트는 피하시는 걸 추천드립니다

실습

과제

감사합니다